



同濟大學  
TONGJI UNIVERSITY

## 3S 技术集成与应用期末报告

学 院： 测绘与地理信息学院

专 业： 测绘工程

学 号： 1951726

姓 名： 高扬

指 导 老 师： 宇洁

时 间： 2022 年 12 月 2 日

# 目 录

1 小组部分	3
1.1 实验原理	3
1.1.1 辐射定标原理	3
1.1.2 大气校正原理	3
1.1.3 灰度共生矩阵原理	4
1.1.4 决策树分类原理	5
1.1.5 Sen 斜率估计原理	5
1.2 实验方法	5
1.3 实验步骤	6
1.3.1 数据获取	6
1.3.2 数据预处理	7
1.3.3 特征空间与样本库构建	8
1.3.4 决策树分类	8
1.3.5 分类后处理与精度评定	9
1.3.6 时空变化分析	9
1.4 实验结果（如无特别说明，均以 2013 年数据为例）	9
1.4.1 数据预处理	10
1.4.2 特征空间与样本库构建	11
1.4.3 决策树分类	12
1.4.4 分类后处理与精度评定	13
1.4.5 时空变化分析	14
1.5 实验相关讨论与思考	16
2 个人部分	17
2.1 实验原理	17
2.1.1 Res-UNet 原理	17
2.2 实验方法	17
2.3 实验步骤	17
2.3.1 数据获取	17
2.3.2 Res-UNet 训练、验证与测试	18
2.3.3 蓝藻分割与精度评定	18
2.3.4 时空变化分析	18
2.4 实验结果	18
2.4.1 Res-UNet 训练、验证与测试	19
2.4.2 蓝藻分割与精度评定	20
2.4.3 时空变化分析	22
2.5 实验相关讨论与思考	23

# 1 小组部分

## 1.1 实验原理

### 1.1.1 辐射定标原理

辐射定标是根据一定的参数将遥感图像的数据量化值转换为具有物理意义的值。有两种转换方式：①转换为绝对辐射亮度值（辐射率）（对应 ENVI 辐射定标的定标类型：辐射率数据）；②转换为与地表（表现）反射率（对应 ENVI 辐射定标的定标类型：反射率）、表面温度等物理量有关的相对值。这里因为后续的 6S 模型需要输入辐射亮度，转化为绝对辐射亮度值，公式为

$$L = gain * DN + bias \quad (1.1)$$

其中 $L$ 是该波段的辐射亮度值， $gain$ 和 $bias$ 分别是增益和偏移， $DN$ 是传感器探测元件输出的值。

特别地，对于 Landsat5 影像 1 级产品，辐射定标公式为

$$L_{\lambda} = G_{rescale} Q_{cal} + B_{rescale} \quad (1.2)$$

其中， $Q_{cal}$  表示 1 级产品的 $DN$ 值， $G_{rescale}$  ( $DN/(W \cdot m^{-2} \cdot sr^{-1} \cdot \mu m^{-1})$ ) 和  $B_{rescale}$  ( $W/(m^2 \cdot sr \cdot \mu m)$ ) 分别是变换的增益和偏置， $L_{\lambda}$  表示传感器入瞳处的光谱辐射亮度 ( $W/(m^2 \cdot sr \cdot \mu m)$ )。对于 2007 与 2010 年的 Landsat5 影像， $G_{rescale}$  与  $B_{rescale}$  各波段的值如下：

表 1.1 Landsat5 影像辐射定标采用的参数值

波段	1	2	3	4	5	6	7
$G_{rescale}$	0.762824	1.442510	1.039880	0.872588	0.119882	0.055158	0.065294
$B_{rescale}$	-1.52	-2.84	-1.17	-1.51	-0.37	1.2378	-0.15

### 1.1.2 大气校正原理

#### A. 6S 大气校正模型

地表和海面的卫星与航空遥感中，由于大气的存在，可见光和近红外波段数据在太阳-表面-传感器之间传输的过程中发生失真，从而不能准确地反映表面真实的辐射特性。

Gordon 在研究海洋遥感计算中的大气校正时，提出了基于 M-C 模拟方法的大气校正方法，即 5S 计算模型。5S 模型计算公式如下：

$$\rho_{TOA}(\theta_s, \theta_v, \phi_s - \phi_v) = Tg(\theta_s, \theta_v) \left[ \rho_{R+A} + T^{\downarrow}(\theta_s) T^{\uparrow}(\theta_v) \frac{\rho_s}{1 - S \rho_s} \right] \quad (1.3)$$

其中， $\rho_{TOA}$  表示大气层顶的反射率， $\theta_s$  与  $\phi_s$  分别表示太阳的天顶角与方位角， $\theta_v$  与  $\phi_v$  分别表示卫星传感器的天顶角与方位角； $Tg$  表示气态传输，对于太阳辐射， $H_2O$ ， $CO_2$ ， $O_2$  与  $O_3$  是主要的吸收气体。 $\rho_{R+A}$  表示分子与气溶胶层的内部反射率， $T^{\downarrow}(\theta_s) T^{\uparrow}(\theta_v)$  表示大气层在太阳和表面之间的总辐射传输量（对应地，表面与传感器间的）， $S$  表示大气层的球面反照率， $\rho_s$  则由  $\rho = \pi L / \mu_s E_s$  计算。

6S(Second Simulation of the Satellite Signal in the Solar Spectrum)模型在 5S 的基础上发

展起来，在计算的原理上和 5S 是一样的。6S 和 5S 相比具有以下不同点：①适用于各类遥感器如航空观察；②能够模拟一定海拔高度处的目标物和非朗伯表面；③计算气体透过率时考虑了新的一些气体如 CO，CH<sub>4</sub> 和 N<sub>2</sub>O，并考虑了瑞利和气溶胶散射效应，计算精度有所提高；④波谱分辨率提高到了 2.5 纳米；⑤在实际计算中，更加逼近于真实情况，把大气的影响效应和地面目标的 BRDF 统一考虑，并将模型解释为四个不同的辐射传输过程，从而能够较好地解决大气-BRDF 的耦合效应。

### B. FLAASH 大气校正模型

基于太阳波谱范围内 (不包括热辐射) 和平面朗伯体 (或近似平面朗伯体)，在传感器处接收的像元光谱辐射亮度公式为：

$$L = \left( \frac{A \cdot \rho}{1 - \rho_e \cdot S} \right) + \left( \frac{B \cdot \rho}{1 - \rho_e \cdot S} \right) + (L_a) \quad (1.4)$$

其中， $L$  表示传感器处像元接收到的总辐射亮度； $\rho$  表示像素表面反射率； $\rho_e$  表示像素周围的平均表面反射率； $S$  表示大气球面反照率； $L_a$  表示大气后向散射辐射率 (大气程辐射)； $A$ ， $B$  是取决于大气条件和几何条件的两个系数。

FLAASH 模型支持的传感器种类多，算法精度高，通过图像像素光谱上的特征来估计大气的属性，不依赖遥感成像时同步测量的大气参数数据，并且可以有效去除水蒸气、气溶胶散射与邻近效应，对因人为抑制而导致的波谱噪声进行光谱平滑处理。

#### 1.1.3 灰度共生矩阵原理

灰度共生矩阵即从灰度为  $i$  的像素点出发，距离  $(dx, dy)$  的另一像素点灰度为  $j$  的概率。Haralick 提出了 14 种基于灰度共生矩阵计算出来的统计量：能量、熵、对比度、均匀性、相关性、方差、和平均、和方差、和熵、差方差、差平均、差熵、相关信息测度以及最大相关系数。在本次小组实验中，我们首先计算了八个常用的灰度共生矩阵，并通过目视判读选取了其中的熵与均匀性两个灰度共生矩阵作为特征。其计算公式如下：

熵 (Entropy):

$$\text{Entropy} = \sum_{i,j=0}^{N-1} P_{i,j} (-\ln P_{i,j}) \quad (1.5)$$

均匀性 (Angular Second Moment):

$$ASM = \sum_{i,j=0}^{N-1} P_{i,j}^2 \quad (1.6)$$

其中， $P_{i,j}$  由以下公式计算：

$$P_{i,j} = \frac{V_{i,j}}{\sum_{i,j=0}^{N-1} V_{i,j}} \quad (1.7)$$

$i, j$  是像素的行列号， $V_{i,j}$  是像素的值， $P_{i,j}$  是归一化后的像素值， $N$  是图像行或列的数量。

#### 1.1.4 决策树分类原理

决策树是预测建模机器学习的一种重要算法：利用给定的样本集，从数据中学习出决策规则，自动构建决策树，随后基于树结构进行预测。根据划分选择的方法不同，最流行的决策树算法包括 ID3, CHAID, CART, QUEST 和 C4.5 等。创建决策树的算法如下：

---

**Algorithm 1** 递归创建分支 CreateBranch

---

```
if 数据集中的每个子项属于同一分类 then
    return 类标签
else
    寻找划分数据集的最好特征
    划分数据集
    创建分支节点
    for 每个划分的子集 do
        调用函数 CreateBranch 并增加返回结果到分支节点中
    end for
    return 分支节点
end if
```

---

#### 1.1.5 Sen 斜率估计原理

Theil-Sen Median 方法又被称为 Sen 斜率估计，是一种稳健的非参数统计的趋势计算方法。该方法对于测量误差和离群数据不敏感。计算公式如下：

$$\beta = \text{mean}\left(\frac{x_j - x_i}{j - i}\right), \forall j > i \quad (1.8)$$

### 1.2 实验方法

小组实验与个人实验所采用的方法流程图如图 1.1 所示：

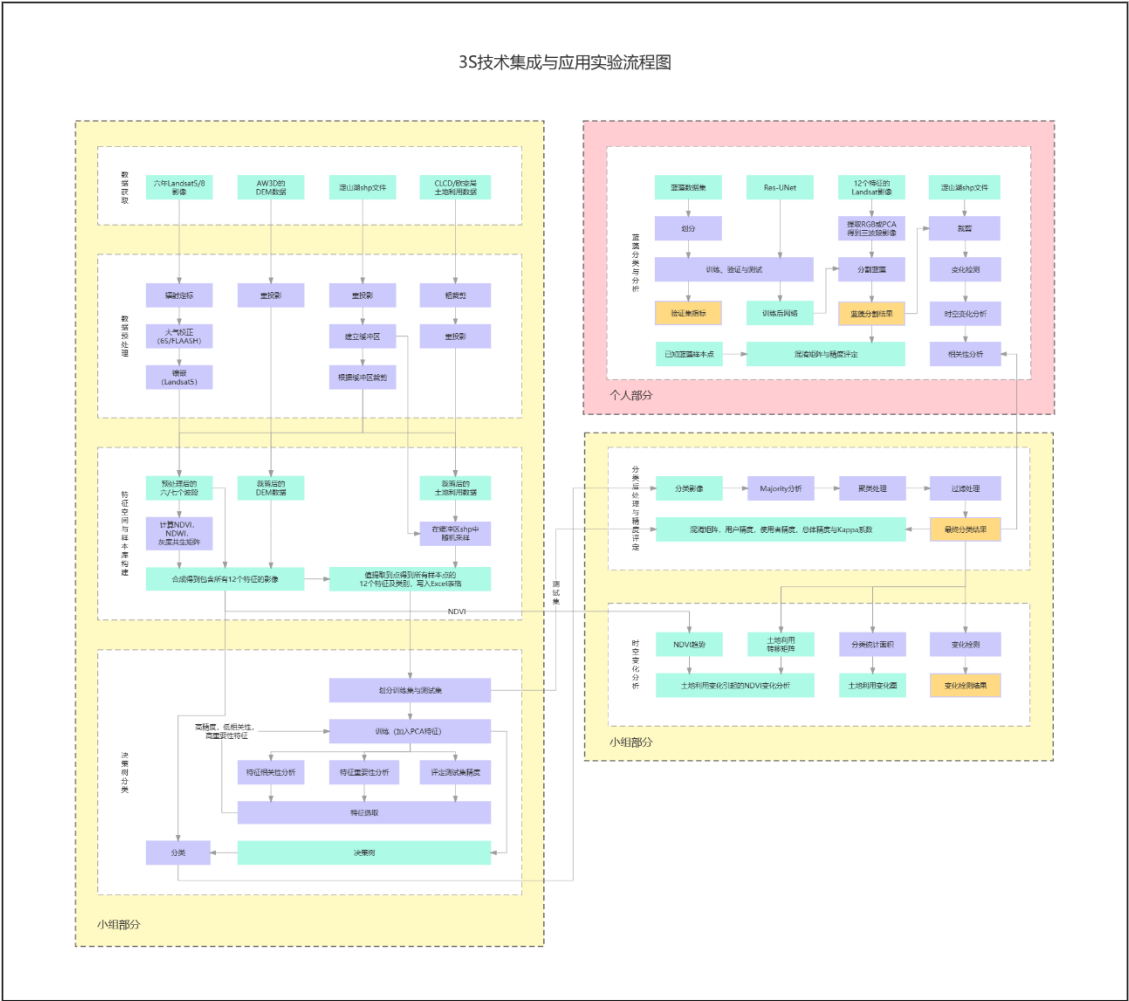


图 1.1 3S 技术集成与应用实验流程图

在大气校正中，我们使用了 6S 方法，并将其与 ENVI 自带的 FLAASH 方法进行了对比。在特征空间构建中，我们使用了原始的六/七个波段，NDVI，NDWI 与两个灰度共生矩阵作为特征，并提取了 PCA 特征，随后经过特征的相关性、重要性与精度分析，选取出了 9 个特征+PCA 特征作为最终的特征。将这些特征输入决策树进行分类，随后对分类后的图像依次进行 Majority 分析、聚类处理与过滤处理，最后进行精度评定，结合 NDVI 进行时空变化分析。

### 1.3 实验步骤

#### 1.3.1 数据获取

在本次小组实验中，我们使用了以下数据：

- (1) 从 USGS 官网下载得到(<https://earthexplorer.usgs.gov/>)的分辨率为 30m 的 2007，2010 两年的淀山湖区域的 Landsat5 遥感影像，以及 2013，2016，2019，2022 四年的淀山湖区域的 Landsat8 遥感影像。
- (2) 从 AW3D 官网下载的 30m DEM 数据

(<https://www.eorc.jaxa.jp/ALOS/en/aw3d30/data/index.htm>)。

(3) 老师提供的淀山湖 shp 文件。

(4) 2007, 2010, 2013, 2016, 2019 五年的 CLCD 土地利用数据(<https://zenodo.org/record/4417810#.Y3WkvMdBzZQ>), 数据分辨率为 30m。

(5) 2021 年的欧空局土地利用数据(<https://worldcover2021.esa.int/>), 数据分辨率为 10m。

### 1.3.2 数据预处理

#### A. 辐射定标

对于 Landsat5 与 Landsat8 影像, 需要首先进行辐射定标。利用正则表达式读取影像头文件中的 RADIANCE\_MULT\_BAND\_ 以及 RADIANCE\_ADD\_BAND\_ , 根据 1.1.1 中的公式计算即可进行辐射定标。

#### B. 大气校正

本次实验中, 我们用了 6S 与 FLAASH 两种大气校正模型, 并对其结果进行了比较。利用 Py6S 库, 通过 Python 代码计算可以进行 6S 模型的校正, 其中有一项 550nm 气溶胶光学厚度的参数, 需要在 NASA 网站([https://aeronet.gsfc.nasa.gov/cgi-bin/type\\_piece\\_of\\_map\\_opera\\_v2\\_new](https://aeronet.gsfc.nasa.gov/cgi-bin/type_piece_of_map_opera_v2_new))上查阅得到。

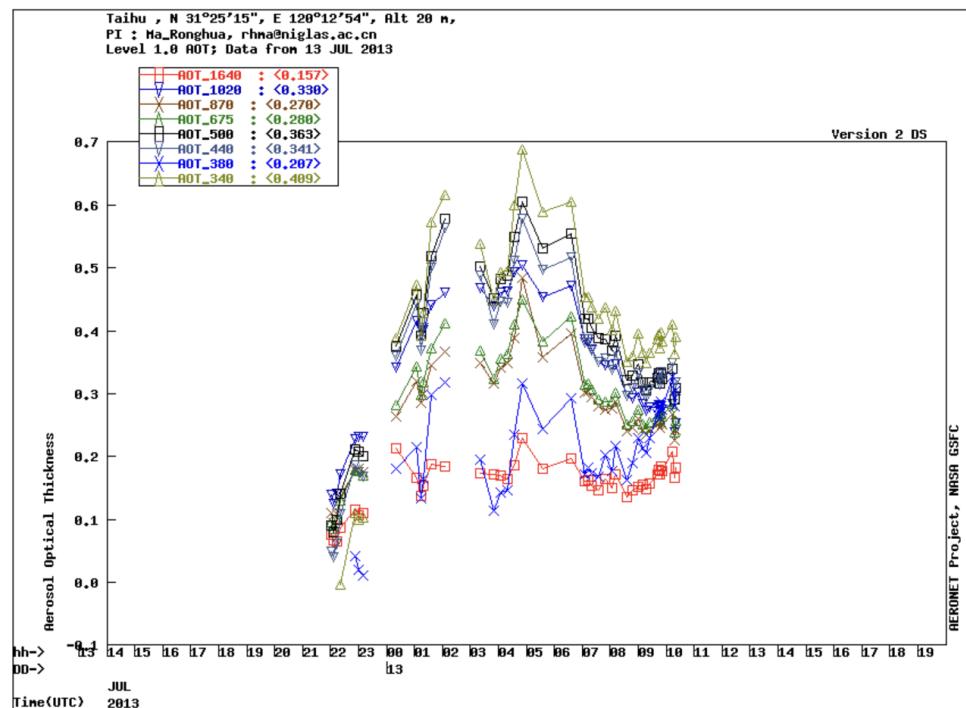


图 1.2 550nm 气溶胶光学厚度随月份变化图

模型中输入的其他参数见下表:

表 1.2 6S 模型输入的参数表

参数	来源	本实验采用数值
Altitude	根据研究区域自定义	2.92 m
Aerosol_Model	根据研究区域自定义	3 (Urban)
solar_z	影像头文件	/
solar_a	影像头文件	/
aot550	NASA 网站	/
b_lat	影像头文件	/
b_lon	影像头文件	/

对于 FLAASH 模型，我们直接使用了 ENVI 中的大气校正模块进行处理。将 FLAASH 模型和 6S 模型得到的大气校正结果进行相减，可以发现差距比较大的地方是在建筑物。

#### C. 其他预处理操作

除辐射定标与大气校正外，对于 Landsat5 影像还需要进行镶嵌处理；另外，DEM 数据、淀山湖 shp 文件与土地利用数据均需要进行重投影（欧空局的土地利用数据需要先重采样到 30m 分辨率），将它们的坐标系统一转换为 WGS\_1984\_UTM\_Zone\_51N 坐标系。特别地，由于 CLCD 土地利用数据是全国范围的，重投影处理起来比较久，可以先根据淀山湖的范围粗裁剪后再重投影。

依据淀山湖 shp 文件，我们建立了一个 8000m 的矩形缓冲区，并根据缓冲区对前述预处理后的各个 Landsat 波段数据、重投影后的 DEM 数据以及土地利用数据进行裁剪。上述步骤可以通过 C# ArcEngine 或 Python gdal 库完成，代码详见小组成果，在此不再赘述。

### 1.3.3 特征空间与样本库构建

#### A. 特征空间构建

由 1.3.2 中得到的预处理后的六个 (Landsat5) 或七个 (Landsat8) 波段的数据，我们计算了 NDVI 与 NDWI 指数与八个常用的灰度共生矩阵（公式参见 1.1.3），通过目视判读，我们选取了熵与均匀性两个灰度共生矩阵特征，并将其与 1.3.2 中得到的 DEM 数据以及六/七个 Landsat 的波段一起合成了包含所有 12 个（Landsat5 为 11 个）特征的影像。

#### B. 样本库构建

在 1.3.2 C 中建立的淀山湖 8000m 缓冲区内，通过 ArcGIS 随机采点，并将上一步的 12 个波段（即 12 个特征）的影像各波段的值以及土地利用数据按值提取到点，写入 Excel 表格，作为决策树分类的训练集。考虑到 CLCD 数据集的分类类别，我们将训练集标注为三类，分别为 building, plant 以及 water。

### 1.3.4 决策树分类

将 1.3.3 中得到的 Excel 表格读入代码，按照 4:1 的比例划分为训练集与验证集。利用



Scikit-Learn 库中的 Pipeline 接口串联 StandardScaler, PCA 特征分析与决策树分类, 并利用 GridSearchCV 自动寻找最优参数。这样可以较好地解决输入的特征量级不一样与决策树的超参数需要调节的问题。通过对特征相关性与贡献度的分析, 我们分别实验了 12 个特征, 12 个特征+PCA, 10 个特征 (除去 NDWI 与均匀性), 10 个特征+PCA, 9 个特征 (除去 NDWI, 均匀性与 band1) 以及 9 个特征+PCA 六种特征空间, 最终在 9 个特征+PCA 的情况下精度最高, 为 80.5%。因此, 我们最终采用了 9 个特征+PCA 作为训练特征, 并对所有年份的影像进行了分类。

我们也在 2019 年的影像上, 采用不同的样本数量测试了精度。采用 1000 个样本点时精度最高, 为 83.1%。

### 1.3.5 分类后处理与精度评定

这一步我们主要采用了 ENVI 软件完成。分类后处理主要包括 Majority 分析, 聚类处理与过滤处理。Majority 分析采用类似于卷积滤波的方法将较大类别中的虚假像元归到该类中。聚类处理运用数学形态学算子 (腐蚀和膨胀), 将临近的类似分类区域聚类并进行合并。过滤处理则可以使用斑点分组方法消除被隔离的分类像元, 解决分类图像中出现的孤岛问题。

处理后, 我们在验证集上评定了分类的精度。评价指标包括混淆矩阵、用户精度、使用者精度、总体精度与 Kappa 系数, 详见 1.4.4。

### 1.3.6 时空变化分析

时空变化分析主要包括变化检测、土地利用变化与 NDVI 分析。

利用 ENVI 变化检测工具可以得到各年的变化检测结果图。同样利用 ENVI 每年分类统计面积, 可以制作出土地利用随年份变化的柱状图。结果详见 1.4.5。

根据 1.1.5 中公式可以计算得到 2007 至 2022 年研究区域 NDVI 的 Sen 趋势图, 结合 ENVI 计算得到的 2007 到 2022 年的土地利用转移矩阵, 可以分析土地利用变化引起的 NDVI 变化如下: 由 plant 转换为 building 主要导致了该区域 NDVI 减少; 而 plant 和 building 的互相转换共同导致了 NDVI 的增加, 个中缘由需要结合蓝藻变化情况进行进一步分析。

## 1.4 实验结果 (如无特别说明, 均以 2013 年数据为例)

1.4.1 数据预处理

A. 辐射定标

```
RADIANCE_MULT_BAND_1 = 1.2149E-02  
RADIANCE_MULT_BAND_2 = 1.2441E-02  
RADIANCE_MULT_BAND_3 = 1.1464E-02  
RADIANCE_MULT_BAND_4 = 9.6675E-03  
RADIANCE_MULT_BAND_5 = 5.9160E-03  
RADIANCE_MULT_BAND_6 = 1.4713E-03  
RADIANCE_MULT_BAND_7 = 4.9589E-04  
RADIANCE_MULT_BAND_8 = 1.0941E-02  
RADIANCE_MULT_BAND_9 = 2.3121E-03  
RADIANCE_MULT_BAND_10 = 3.3420E-04  
RADIANCE_MULT_BAND_11 = 3.3420E-04
```

图 1.3 利用正则表达式读取得的头文件图

B. 大气校正

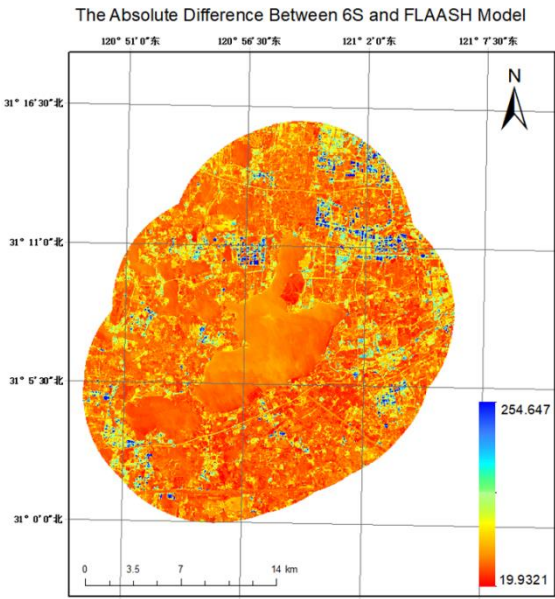


图 1.4 6S 模型与 FLAASH 模型大气校正结果比较图




图 1.5 经过辐射定标与 6S 模型大气校正后的结果图

### C. 其他预处理操作



图 1.6 重投影并裁剪后的 DEM 数据

### 1.4.2 特征空间与样本库构建

#### A. 特征空间构建

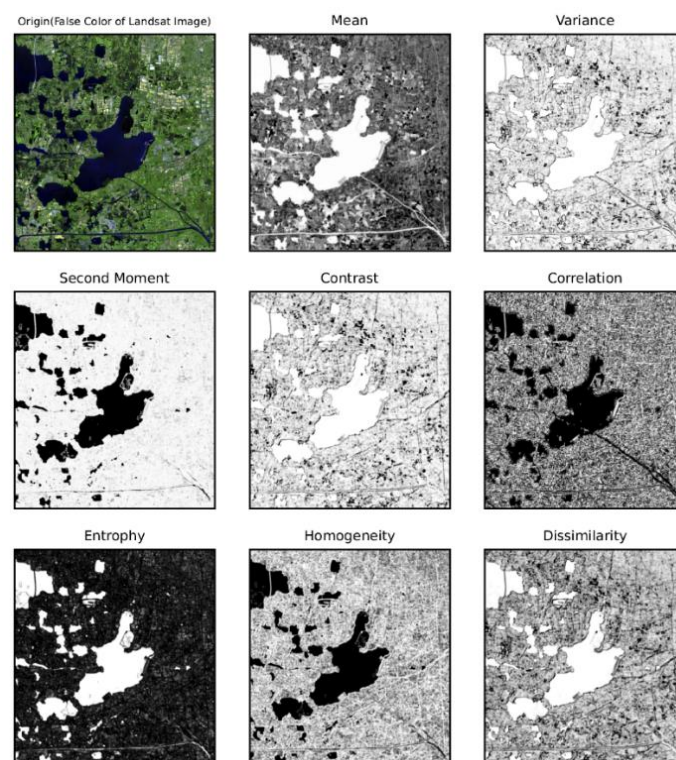


图 1.7 八个灰度共生矩阵与假彩色影像比较图

B. 样本库构建

	A	B	C	D	E	F	G	H	I	J	K	L	M	N	O	P
1	ID	MapX	MapY	B1	B2	B3	B4	B5	B6	B7	NDVI	NDWI	DEM	Entroph	SecondMoment	Type
2	1	297224	3434810	802.406	622.651	670.529	414.897	724.888	273.755	197.093	0.271973	-0.03896	6	213	16	3
3	2	309472	3433833	921.75	785.012	818.75	588.148	271.753	192.667	148.512	-0.36794	0.501601	2	206	20	3
4	3	294404	3457269	1273.43	1213.78	1500.24	1317.21	482.37	69.828	61.6326	-0.46391	0.513399	0	129	54	3
5	4	292160	3436943	859.902	670.947	653.659	414.294	220.592	104.491	76.9508	-0.3051	0.495358	3	211	22	3
6	5	304997	3441910	957.678	842.659	962.867	699.396	222.151	119.817	104.714	-0.51787	0.625067	1	0	255	3
7	6	303819	3459074	821.852	623.02	603.355	364.495	167.068	64.1685	49.6651	-0.37141	0.566295	0	53	159	3
8	7	300569	3446755	968.974	841.192	914.2	623.948	169.667	75.0158	64.9835	-0.57242	0.686923	0	0	255	3
9	8	300052	3446792	875.678	724.707	766.583	486.964	175.124	79.4961	66.8983	-0.47099	0.628071	1	79	99	3
10	9	310011	3432651	710.303	504.808	585.789	298.644	643.162	359.539	225.332	0.385806	-0.04668	5	251	5	3
11	10	300770	3434703	2216.75	2171.87	1663.03	1345.48	3342.5	3156.81	2856.71	0.425987	-0.33552	7	251	5	3
12	11	302371	3451320	874.06	688.261	760.521	426.059	2170.45	908.479	415.556	0.671822	-0.48105	-1	153	54	3
13	12	301789	3442308	1028.22	925.867	1039.97	793.962	261.108	156.362	134.631	-0.50504	0.598628	1	0	255	3
14	13	306203	3455463	958.081	763.327	911.849	620.64	739.882	390.88	287.069	0.087644	0.104113	4	251	5	3
15	14	300775	3450005	904.783	754.135	798.899	528.841	167.847	92.9368	78.3869	-0.51816	0.652759	1	27	229	3
16	15	305265	3449133	1076.11	869.436	883.634	750.148	1235.02	1061.66	859.009	0.244247	-0.16585	6	255	2	3
17	16	302675	3451206	834.405	617.486	557.061	312.847	140.035	70.5355	54.2128	-0.38158	0.598233	-5	158	68	3
18	17	300578	3446837	923.769	785.746	855.404	566.479	146.014	61.5746	52.298	-0.59013	0.708385	0	0	255	3
19	18	299918	3439644	799.164	635.56	613.487	339.431	108.836	81.6184	74.5574	-0.51441	0.69865	2	195	31	3
20	19	298349	3434514	861.925	695.627	732.899	601.388	674.722	553.669	446.419	0.057467	0.04133	-1	208	18	3
21	20	305474	3445293	1055.19	946.734	1025.23	775.659	274.09	164.142	141.332	-0.4778	0.578102	1	0	255	3
22	21	294699	3436288	854.642	669.474	665.468	394.681	194.353	119.345	89.8753	-0.3401	0.547922	-3	122	87	3
23	22	307377	3449860	925.789	764.797	802.937	568.285	210.981	103.548	83.1738	-0.45851	0.58383	2	81	98	3
24	23	296616	3439218	771.191	559.154	476.202	251.482	85.4296	50.0195	42.9632	-0.49287	0.695781	1	0	255	3
25	24	292407	3433076	974.217	805.583	811.012	496.908	484.442	173.572	95.8588	-0.0127	0.252089	2	251	5	3
26	25	310151	3446647	976.233	855.133	947.097	667.243	182.66	97.8885	83.6524	-0.57016	0.676638	1	17	234	3
27	26	304577	3441386	924.173	812.56	919.236	704.803	214.098	108.499	93.4654	-0.53401	0.62218	1	72	121	3
28	27	307614	3439269	989.539	839.357	1368.57	751.048	2869.12	1162.81	575.599	0.585076	-0.3541	3	255	3	3
29	28	315104	3455378	1169.69	1033.38	1328.94	1128.82	3081.44	2213.31	1474.06	0.463777	-0.39736	3	255	3	3
30	29	303383	3444082	1134.77	1030.46	1130.34	887.495	371.148	223.548	181.777	-0.41024	0.505626	2	0	255	3

图 1.8 样本库 Excel 表例

1.4.3 决策树分类

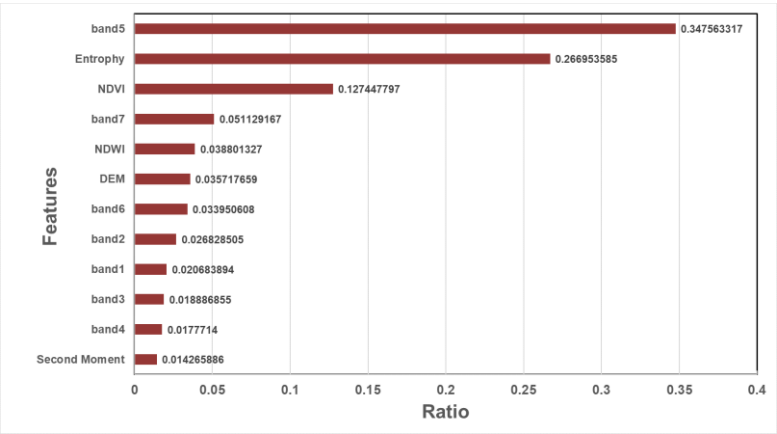


图 1.9 12 个特征重要性图




图 1.10 12 个特征间的相关性热力图



表 1.3 不同特征组合下的 Accuracy 对比

特征组合	Accuracy(%)
12 个特征(波段*7+DEM+NDVI+NDWI+GLCM*2)	76.4
12 个特征+PCA	76.9
10 个特征(波段*6+DEM+NDVI+GLCM*1)	79
10 个特征+PCA	76.9
9 个特征(波段*5+DEM+NDVI+GLCM*1)	77.9
<b>9 个特征+PCA</b>	<b>80.5</b>

表 1.4 不同样本数量下的 Accuracy 对比（以 2019 年为例）

样本数量（个）	Accuracy(%)
500	77.8
<b>1000</b>	<b>83.1</b>
2000	82

#### 1.4.4 分类后处理与精度评定

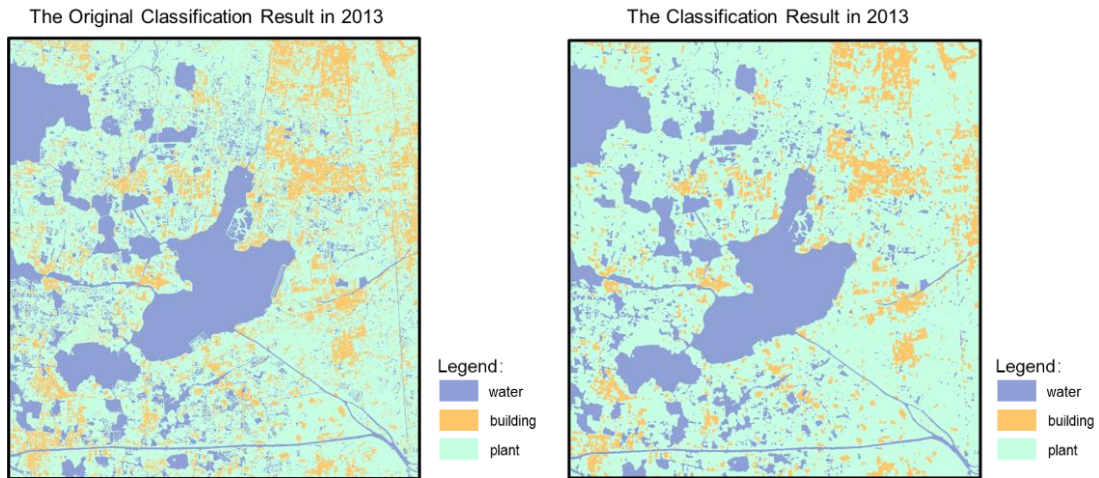


图 1.11 分类后处理前与处理后的结果图

表 1.5 不同特征组合下的 Accuracy 对比

2013 混淆矩阵		预测值		
		building	plant	water
真实值	building	10	8	3
	plant	10	104	3
	water	1	13	43

表 1.6 2013 年的用户精度与使用者精度

类别	building	plant	water
生产者精度	0.48	0.83	0.88
用户精度	0.48	0.89	0.75

表 1.7 六年的总体精度与 Kappa 系数

年份	2007	2010	2013	2016	2019	2022
总体精度	0.84	0.76	0.81	0.80	0.83	0.75
Kappa 系数	0.71	0.60	0.63	0.68	0.66	0.61

1.4.5 时空变化分析

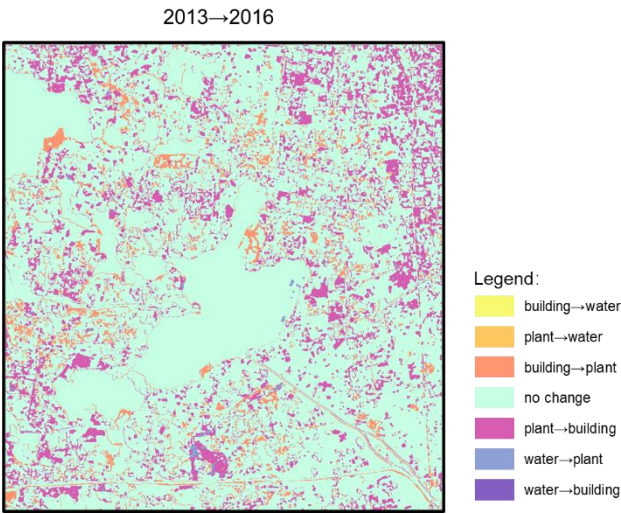


图 1.12 2013 至 2016 年变化检测结果图




图 1.13 2007 至 2022 年 NDVI 变化统计图




图 1.14 2007 至 2022 年土地利用情况变化图

表 1.8 2007 至 2022 年土地利用转移矩阵

单位：平方千米		2007			Total
		building	plant	water	
2022	building	90.62	101.84	11.18	203.64
	plant	30.68	313.65	53.51	397.84
	water	8.26	25.73	171.16	205.16
	Class Total	129.57	441.22	235.86	
	Class Changes	38.94	127.57	64.70	
	Image Difference	74.07	-43.37	-30.70	

The Sen Trend of NDVI from 2007 to 2022




图 1.15 2007 至 2022 年 NDVI Sen 趋势图

## 1.5 实验相关讨论与思考

在本次小组实验中，我们还有许多不完善之处。

在数据上，我们可以对于采样的样本点再加一步是否为混合像元的判断，减少训练集的错误类别标签。另外，还可以结合更多的开源数据。我们尝试了夜光遥感数据，但因为研究区面积太小，夜光遥感数据分辨率又比较低，没有取得很好的效果。

在代码上，由于裁剪后的影像可能有些部分会是 NoData 值，在应用决策树分类时需要首先判断该像元是否为 NoData 值。因此，我们对整幅影像的每个像素进行了循环判断，在运行中占用了大量的时间。未来我们可以将 NoData 的标记改为使用 `np.ma` 进行掩膜，这样在决策树分类时就无需进行额外的判断，可以大大减少运行时间。另外，我们也可以采用 CUDA 或 Numba 加速。

最后，决策树并不一定是表现最好的机器学习算法。由决策树发展而来的随机森林与集成学习可能精度更高。在时空变化分析中，我们还可以尝试使用地理探测器。



## 2 个人部分

### 2.1 实验原理

#### 2.1.1 Res-UNet 原理

Res-UNet 网络由语义分割网络 UNet 改进而来，在每个两次卷积后池化的 block 的基础上增加了残差模块，可以较好地解决模型过深时出现的过拟合问题。Res-UNet 的网络结构如图 2.1 所示。




图 2.1 Res-UNet 网络结构图

### 2.2 实验方法

在个人部分，我利用 Kaggle 上的蓝藻无人机影像数据集 (<https://www.kaggle.com/datasets/beyondstellaris/bluegreen-algae-dataset>) 对自己搭建的 Res-UNet 网络进行训练，验证与测试。随后将小组部分处理得到的包含 12 个特征波段的蓝藻影像提取出真彩色波段组合，同时对 12 个特征波段的影像进行 PCA 主成分分析得到三个波段值；将两种方法得到的三个波段都使用训练好的网络进行分割，并比较结果。比较后决定采用真彩色波段组合，对 2007，2013 与 2022 三年的 Landsat 影像进行分割。随后依据老师提供的蓝藻样本点计算混淆矩阵，评定精度。最后，将分割结果用淀山湖 shp 文件进行进一步裁剪，利用 ENVI 完成变化检测，时空变化分析与相关性分析。具体流程图见图 1.1。

### 2.3 实验步骤

#### 2.3.1 数据获取

在本次个人实验中，使用了以下数据：

- (1) Kaggle 上的蓝藻无人机影像数据集 (<https://www.kaggle.com/datasets/beyondstellaris/bluegreen-algae-dataset>)。
- (2) 小组部分(1.3.3)得到的包含 11(12)个特征波段的 2007, 2013 与 2022 三年的 Landsat5(8)遥感影像。

(3) 老师提供的淀山湖 shp 文件。

### 2.3.2 Res-UNet 训练、验证与测试

个人实验中写的代码全部位于 `code` 文件夹下，使用方法与说明参见 `README.md`，在此不再赘述。在训练时，由于我的电脑无法使用 `cuda`，因此我尝试了在 Google Colab 上进行训练，但不久后达到了免费时长，所幸在代码中写了保存断点的部分，随后在淘宝租借服务器完成了剩下的训练。由于时间原因，只训练了 50 个 `epoch`，但从训练与验证的损失曲线及各项指标来看，网络训练应该没有问题。

验证与测试同样在代码中完成，验证集评价指标有 `F1score`，`MIoU` 与像素精度。模型训练完成后，在测试集的图片 `33.png` 上进行测试，验证与测试结果参见 2.4.1。经过 50 个 `epoch` 的训练，验证集的 `F1score` 达到了 0.88，`MIoU` 达到了 84%，像素精度为 93%。

### 2.3.3 蓝藻分割与精度评定

代码参见 `predict.py`。

#### A. 蓝藻分割

由于用于训练的影像是无人机彩色影像，在将网络用于遥感影像时我尝试了两种波段组合：真彩色波段与 PCA 得到三个波段。读入遥感影像，分别计算出两种波段组合，再利用 2.3.2 中训练好的 Res-UNet 进行分割。根据目视判断，真彩色波段组合分割结果较好，因此对三年的遥感影像都使用真彩色波段组合进行分割。分割结果参见 2.4.2。

#### B. 精度评定

读取老师提供的蓝藻样本点坐标，计算出它们在图像上的坐标，再查找对应的像素类别，即可据此计算出混淆矩阵与总体精度。

### 2.3.4 时空变化分析

时空变化分析主要包括变化检测、综合小组得到的土地利用类型变化的时空变化分析与相关性分析。变化检测与转移矩阵同样利用 ENVI 软件计算得到，结果见 2.4.3。

时空变化分析与相关性分析如下：

#### A. 时空变化分析

结合转移矩阵与变化检测结果可以得到：2007 至 2013 年淀山湖周围较大部分水体转化为了蓝藻，湖北面与南面有少量蓝藻减少；2013 至 2022 年湖周围较大部分蓝藻消失，湖北面有少量水体转化为蓝藻。综合来看，蓝藻集中分布于湖沿岸一带，2013 年的蓝藻含量最多。

#### B. 相关性分析

由小组部分的成果来看，2022 年建筑物最多，2013 年植被最多，2007 年水体最多；然而从蓝藻含量上来看，2022 年蓝藻最少，其次是 2007 年，2013 年蓝藻最多。从常理来说，建筑物增多表示人类活动增加，更可能导致水体富营养化，从而引发蓝藻增加；而植被的增加则有利于抑制蓝藻的增长。但从小组与个人的成果来看，却有违这两条事实。因此，我们的小组成果或我的个人成果应当存在一定的问题。

## 2.4 实验结果

### 2.4.1 Res-UNet 训练、验证与测试




图 2.2 Res-UNet 训练损失图

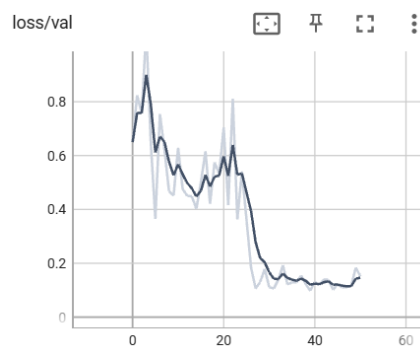


图 2.3 Res-UNet 验证损失图

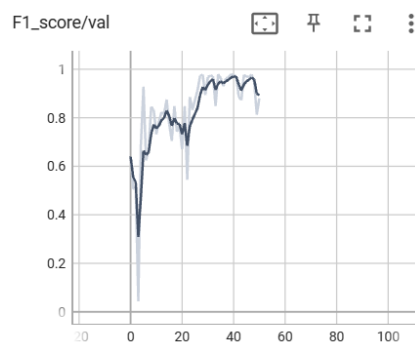


图 2.4 Res-UNet 验证 F1score 图




图 2.5 Res-UNet 验证 MIoU 图

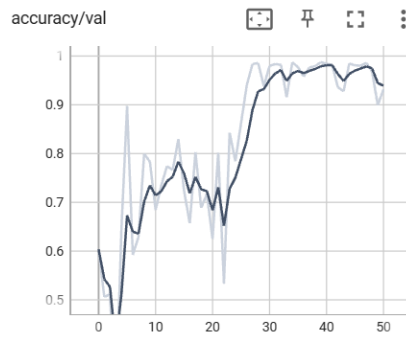


图 2.6 Res-UNet 验证像素精度图



图 2.7 模型在测试集的 33.png 上分割的结果（左为真值，右为预测值）

## 2.4.2 蓝藻分割与精度评定

### A. 蓝藻分割（黄色为水体，蓝色为蓝藻）




图 2.8 2007 年 Landsat5 影像分割结果（真彩色）




图 2.9 2007 年 Landsat5 影像分割结果 (PCA)




图 2.10 2013 年 Landsat8 影像分割结果 (真彩色)




图 2.11 2022 年 Landsat8 影像分割结果 (真彩色)

## B. 精度评定

表 2.1 三年分别采用真彩色图像与 PCA 的精度				
年份		2007	2013	2022
特征	真彩色	0.12	0.33	0.11
	PCA	0.15	0.11	0.26

2.4.3 时空变化分析

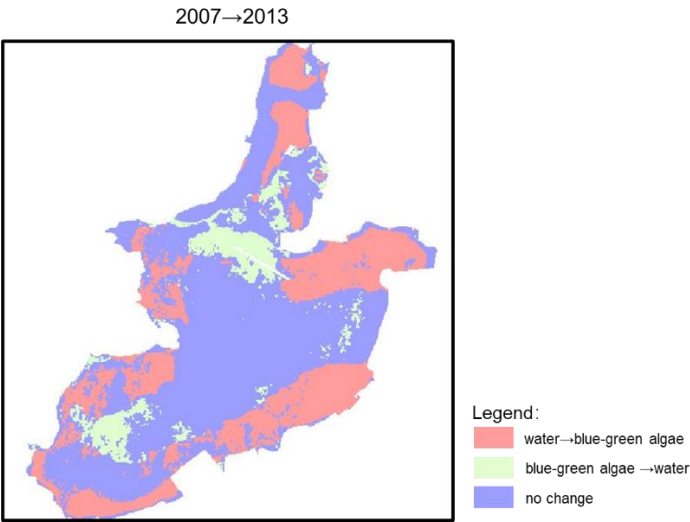


图 2.12 2007 至 2013 年变化检测结果图

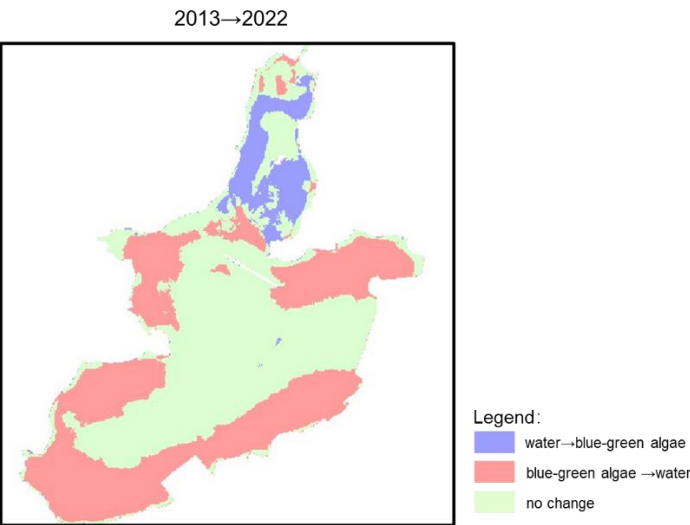


图 2.13 2013 至 2022 年变化检测结果图（不知道为什么 ArcGIS 渲染出来颜色顺序不太一样）

表 2.2 2007 至 2022 年蓝藻与水体转移矩阵				
单位：平方千米		2007		
		water	blue-green algae	Class Total
2022	water	39.06	13.4622	52.5222
	blue-green algae	6.3369	1.1232	7.4601
	Class Total	45.3969	14.5854	
	Class Changes	6.3369	13.4622	
	Image Difference	7.1253	-7.1253	

## 2.5 实验相关讨论与思考

本次个人实验仍然有许多未解决的问题，罗列如下：

(1) 在模型验证时，如果加了 `model.eval()` 会导致预测结果全黑，因此我并没有加这一句代码。但按照 `pytorch` 官方的说法，应当在验证与预测时添加 `model.eval()`，否则可能导致预测结果不连续。`model.eval()` 主要作用于网络中的 `BatchNormalization` 层与 `Dropout` 层，对于 `BatchNormalization` 层来说，添加了 `model.eval()` 会在验证时使用训练中保存的图片均值与方差，而不会重新计算。我写的网络中没有 `Dropout` 层，因此我认为 `model.eval()` 只会影响验证时 `BatchNormalization` 层使用的图片均值与方差；但这似乎无法解释预测结果全黑的原因。

(2) 网络训练似乎在训练集、验证集与测试集上表现都很正常，但用于遥感影像分割时精度异常低。我认为原因可能有以下几点：a. 训练的 `epoch` 数量还不够，可以训练更久以获得更好的性能；b. 遥感影像的真彩色波段组合就算归一化到 0-255 的像素范围内，也仍然与无人机拍摄的彩色影像在光谱上有很大的区别，网络在无人机影像上学习的特征无法适用于遥感影像；c. 无人机影像与遥感影像在语义层面也区别较大：无人机影像中近景细节更多，而遥感影像分辨率较低，同样的蓝藻在无人机影像与遥感影像尺度上的图像结构特征可能有较大的区别；d. 用于评价的蓝藻样本点可能有一定的问题，部分样本点在淀山湖的 `shp` 文件范围外，选取得并不是特别准确。

(3) 从土地利用变化与蓝藻分割结果来看，两者的相关性有违常理。因此，我们的小组成果或我的个人成果应当存在问题。

很遗憾未能找到遥感影像用于蓝藻分割的数据集；我所采用的数据集来自 2022 年的论文 *RecepNet: Network with Large Receptive Field for Real-Time Semantic Segmentation and Application for Blue-Green Algae*<sup>i</sup>，据该论文称他们所制作的数据集是第一个蓝藻分割用于深度学习的数据集。该论文也搭建了一个神经网络用于蓝藻分类，但由于论文作者并没有公开源代码，论文中的网络也比较复杂，因此我自己写了一个较为简单的 `Res-UNet` 用于蓝藻分割。

---

<sup>i</sup> Yang, Kaiyuan & Wang, Zhonghao & Yang, Zheng & Zheng, Peiyang & Yao, Shanliang & Zhu, Xiaohui & Yue, Yong & Wang, Wei & Zhang, Jie & Ma, Jieming. (2022). *RecepNet: Network with Large Receptive Field for Real-Time Semantic Segmentation and Application for Blue-Green Algae*. *Remote Sensing*. 14. 5315. 10.3390/rs14215315.